

@asanchezyali

Estudia conmigo:

Matemáticas del Machine Learning

Cómo se puede optimizar el descenso de gradiente



Descenso de gradiente

El paso de primer orden avanza en contra del gradiente, escalado por un tamaño de paso α :

$$x_{k+1} = x_k - \alpha \nabla f(x_k)$$

Obs. solo usa la pendiente, no cómo está cambiando.



Un paso más fino

Un dato extra hace cada paso más inteligente:

$$x_{k+1} = x_k - H^{-1} \nabla f(x_k)$$

...y solo necesita un poco del cálculo que ya conocemos.



Curvatura

Def. La expansión de Taylor ajusta una parábola a f cerca de un punto a :

$$f(x) = f(a) + \frac{f'(a)}{1!}(x - a) + \frac{f''(a)}{2!}(x - a)^2 + \dots$$

Obs. el término cuadrático lleva la curvatura.



Método de Newton (1D)

Sea $a = x_k$ y $x - a = t$, y minimizamos la parábola:

$$f(x_k + t) \approx f(x_k) + f'(x_k)t + \frac{1}{2}f''(x_k)t^2$$

$$\Rightarrow t = -\frac{f'(x_k)}{f''(x_k)}$$




Ejemplo

Ej. para $f(x) = 0.05x^4 - 0.2x^3 - 0.5x^2 + x + 2$ en $x_k = 3.5$:

$$f'(3.5) = -1.275, \quad f''(3.5) = 2.15$$

$$t = -\frac{(-1.275)}{2.15} \approx 0.593 \Rightarrow x_{k+1} \approx 4.093$$



Muchos parámetros

Los modelos reales tienen muchos parámetros, así que f' y f'' pasan a sus análogos multivariados, hechos de derivadas parciales.

Def. El gradiente ∇f es el vector de todas las primeras derivadas parciales:

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \end{bmatrix}$$



La Hessiana

Def. La Hessiana H es la matriz de todas las segundas derivadas parciales:

$$H_f = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

Newton en n dimensiones

Reemplazamos $f' \rightarrow \nabla f$ y $f'' \rightarrow H$:

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

$$x_{k+1} = x_k - H^{-1} \nabla f(x_k)$$

En la práctica

Obs. calcular la Hessiana completa es costoso en modelos con muchas dimensiones.

Por eso normalmente se aproxima H^{-1} – la idea detrás de los métodos quasi-Newton como BFGS.

En el fondo, dos ideas antiguas – la expansión de Taylor y el paso de Newton – todavía dan forma a los algoritmos que entrenan los modelos de hoy.



¿Cuál es tu aplicación favorita del cálculo en machine learning?

Guarda esto para tu próxima sesión de estudio, y cuéntame tu favorita en los comentarios

Sígueme – escribo las notas completas en asanchezyali.com